



**Universidad
Europea**

UNIVERSIDAD EUROPEA DE MADRID

ESCUELA DE ARQUITECTURA, INGENIERÍA Y DISEÑO

**GRADO EN INGENIERIA MATEMATICA APLICADO A LA
CIENCIA DE DATOS**

Actividad 3 OPEN DATA: Datos Estructurados

Martin Eduardo Otero Di Lorenzo

22300471

Indice

Introducción	3
Contexto.....	3
Proceso ETL	5
Dataset principal.....	5
Dataset Aeropuertos	6
Dataset FAA: Modelo Aviones	7
Proceso EDA	9
Rama 0: Análisis General	9
Rama 1: Comparativa de mercado por Modelo y/o Aerolínea	12
Rama 2: Edad de la Aeronave y su efecto	18
Rama 3: Impacto de congestión y Franjas horarias	20
Rama 4: Impacto de TaxiOut, TaxiIn y eventos WheelsOff/WheelsOn.....	23
Conclusiones.....	28
Ideas y Cambios a Futuro	29

Introducción

Este proyecto se centra en el análisis, clasificación y predicción de retrasos de vuelos nacionales en Estados Unidos. Mi propósito es construir un dataset enriquecido que combine información de vuelos con coordenadas de aeropuertos y datos técnicos de aeronaves, de manera que pueda estudiar no solo los retrasos en sí, sino también los factores que los explican. El campo de investigación es amplio: me permite analizar por ruta, por aerolínea operadora frente a comercializadora, por modelo y edad de avión, por franjas horarias y por condiciones geográficas.

Los objetivos principales que me planteé son calcular el retraso medio por ruta y por aerolínea operadora, comparar la puntualidad entre aerolínea operadora y aerolínea comercializadora (code-share), evaluar si ciertos modelos o edades de aeronaves presentan mayor probabilidad de retraso o cancelación, visualizar rutas en mapas coloreadas por retraso medio y, finalmente, construir modelos de clasificación y regresión para predecir tanto la probabilidad como la magnitud del retraso.

La escala del proyecto es significativa: trabajo con millones de registros de vuelos provenientes de Kaggle, miles de aeropuertos con sus coordenadas y metadatos, y decenas de miles de aeronaves con información técnica. Esto exige un proceso ETL robusto y reproducible que garantice consistencia y escalabilidad.

Contexto

Para alcanzar esta escala de proyecto decidí unir tres fuentes de datos distintas. La primera es el dataset de vuelos de Kaggle, específicamente el archivo `Combined_Flights_2022.csv` debido a la gran cantidad de datos, del repositorio Flight Status Prediction. Este dataset es la base principal y contiene información detallada de cada vuelo: fechas, aerolíneas, aeropuertos, retrasos y métricas de tiempo.

La segunda fuente es el dataset de aeropuertos de OurAirports, que me aporta coordenadas (latitud y longitud), nombre y país de cada aeropuerto. Lo integré porque necesitaba extender el análisis hacia la dimensión espacial y poder trazar rutas en mapas. Elegí OurAirports ya que ofrece un CSV público y actualizado con coordenadas que facilita merges directos por código IATA y está ampliamente usado en proyectos geoespaciales. La conexión entre vuelos y aeropuertos la realicé mediante el campo `iata_code`, que funciona como clave para enlazar origen y destino con sus coordenadas y metadatos.

La tercera fuente es la base de datos de la FAA, a la que accedí usando la librería *hangarbay* y credenciales dadas. A partir de los tail numbers de las aeronaves obtuve información sobre modelo, año de fabricación, tipo de motor y número de asientos; la FAA es la fuente oficial de registros de aeronaves en EE. UU., por lo que usarla (o APIs que la consultan) garantiza datos técnicos y de matriculación confiables para enlazar por `Tail_Number`. La conexión se hizo mediante la variable `Tail_Number`, que actúa como clave para vincular cada vuelo con su aeronave y, por extensión, con su modelo y edad.

A continuación, algunas de las características mas importantes de cada dataset. Se incluyen sobre todo las importantes para este análisis y las que se usaron en la unión:

Dataset de vuelos (Kaggle)

- ❖ **FlightDate, sched_dep_dt, dep_dt, sched_arr_dt, arr_dt**: tiempos programados y reales (base para calcular retrasos y franjas horarias).
- ❖ **Airline, IATA_Code_Marketing_Airline, Operating_Airline, IATA_Code_Operating_Airline**: identificación de aerolínea marketing vs operadora (para comparar performance).
- ❖ **Origin, Dest**: códigos IATA de origen y destino (clave para merge con OurAirports).
- ❖ **Tail_Number**: matrícula de la aeronave (clave para merge con FAA/hangarbay).
- ❖ **DepDelayMinutes, ArrDelayMinutes, DepDel15, ArrDel15**: métricas objetivo para clasificación/regresión de delay en vuelos.
- ❖ **CRSElapsedTime, ActualElapsedTime, AirTime, TaxiOut, TaxiIn, WheelsOff, WheelsOn**: métricas operativas usadas para explicar variación en retrasos.
- ❖ **Distance, DistanceGroup**: para normalizar y segmentar por longitud de ruta.
- ❖ **Operated_or_Branded_Code_Share_Partners, Marketing_Airline_Network**: para análisis de code-share y diferencias operadora vs comercializadora.

OurAirports (aeropuertos)

- ❖ **iata_code**: clave primaria para unir con Origin/Dest del dataset de vuelos.
- ❖ **latitude_deg, longitude_deg**: coordenadas para mapeo de rutas y análisis espacial.
- ❖ **name, iso_country**: metadatos para filtros por país y etiquetas en visualizaciones.

FAA / hangarbay (aeronaves)

- ❖ **N-NUMBER / Tail_Number**: matrícula (clave primaria para unir con Tail_Number del CSV).
- ❖ **MODEL (model_code)**: modelo de aeronave (ej. B737-800) para comparar performance por tipo.
- ❖ **YEAR MFR / year_manufactured**: año de fabricación para calcular **aircraft_age** y estudiar efecto de antigüedad.

Proceso ETL

Dataset principal

Comencé el proceso ETL partiendo del **dataset principal** como la fuente de hechos del vuelo. Lo primero que ejecuté fue un análisis de calidad básico para cuantificar la magnitud de nulos en todo el dataset; el resultado global lo guardé como imagen para el informe.

1. **Total** celdas: 248,777,398
2. **Celdas** con NA: 2,047,675 (0.8231 % del dataset total)

A continuación, inspeccioné la presencia de ceros por columna porque en este dominio muchos campos binarios o de conteo aparecen mayoritariamente como 0 y eso puede confundirse con datos faltantes. El porcentaje global de ceros en el dataset resultó ser aproximadamente **10.048 %**, cifra que expliqué y verifiqué en el notebook: en muchos casos esos ceros son esperables (indicadores de no-desvío, no-cancelación o ausencia de retraso) y no errores de captura. A continuación, el conteo de 0s por variable para entender el contexto.

column	zero_count	zero_pct_rows
Diverted	4068108	99.7497
DivAirportLandings	4067580	99.7367
Cancelled	3955126	96.9793
DepDel15	3093187	75.8447
ArrDel15	3090954	75.7899
ArrDelayMinutes	2455178	60.2007
DepDelayMinutes	2398937	58.8217
DepartureDelayGroups	888768	21.7925
ArrivalDelayGroups	709742	17.4028
DepDelay	194518	4.7696
ArrDelay	73966	1.8136

Con esos diagnósticos en mano tomé decisiones concretas sobre limpieza: dado que el porcentaje total de celdas con NA es bajo (0.8231 %), y que las filas con NA no se concentran en variables críticas, decidí droppear las filas con NA en la fase inicial para simplificar el pipeline y evitar imputaciones que pudieran introducir sesgos tempranos; esta decisión está documentada en el notebook y la captura del conteo de nulos acompaña la justificación. Respecto a los ceros, no los eliminé automáticamente porque, como muestran los outputs, muchos representan estados válidos del dominio; en su lugar marqué y documenté las columnas donde 0 es significativo.

También reduje la dimensionalidad eliminando columnas derivables de fecha que sobrecargaban el dataset sin aportar información nueva: Year, Quarter, Month, DayOfMonth, DayOfWeek fueron removidas porque se pueden derivar fácilmente de FlightDate o de los datetimes completos y su presencia multiplica columnas innecesarias en análisis y modelos.

Después validé integridad en por ejemplo Distance, donde apliqué un umbral mínimo para detectar valores irreales y registros no plausibles. Usé threshold de 3 millas como criterio para marcar rutas sospechosas investigando las rutas más cortas en Internet.

Normalicé los campos de tiempo en formato HHMM convirtiendo primero FlightDate a datetime y luego limpiando las cadenas de tiempo: quité sufijos como .0, eliminé caracteres no numéricos y rellené a cuatro dígitos (0728, 0947, 1133). Con esas cadenas adecuadas extraje horas y minutos y sumé pd.to_timedelta a la fecha para crear sched_dep_dt, sched_arr_dt, dep_dt y arr_dt, de modo que valores como CRSDepTime = 1133 pasan a 2022-04-04 11:33:00 y DepTime = 1123 a 2022-04-04 11:23:00.

1.	CRSDepTime		sched_dep_dt	DepTime		dep_dt
2.	0	1133	2022-04-04 11:33:00	1123	2022-04-04 11:23:00	
3.	1	0732	2022-04-04 07:32:00	0728	2022-04-04 07:28:00	
4.	2	1529	2022-04-04 15:29:00	1514	2022-04-04 15:14:00	
5.	3	1435	2022-04-04 14:35:00	1430	2022-04-04 14:30:00	
6.	4	1135	2022-04-04 11:35:00	1135	2022-04-04 11:35:00	
7.	5	0955	2022-04-04 09:55:00	0952	2022-04-04 09:52:00	
8.	6	2139	2022-04-04 21:39:00	2136	2022-04-04 21:36:00	
9.	7	1129	2022-04-04 11:29:00	1117	2022-04-04 11:17:00	
10.	8	1424	2022-04-04 14:24:00	1414	2022-04-04 14:14:00	
11.	9	0954	2022-04-04 09:54:00	0947	2022-04-04 09:47:00	

Tras crear las columnas formato datetime eliminé las columnas originales de texto (CRSDepTime, CRSArrTime, DepTime, ArrTime) para evitar duplicidad y ahorrar recursos, conservando FlightDate como campo útil para análisis diarios y visualizaciones que no requieren resolución por minuto. También reorganice las columnas.

Finalmente normalicé los códigos IATA en las columnas Origin, Dest, IATA_Code_Operating_Airline e IATA_Code_Marketing_Airline para garantizar comparaciones y joins consistentes. Convertí cada valor a str, eliminé espacios en blanco, pasé todo a mayúsculas y quité caracteres no alfabéticos; así evité duplicados por diferencias de formato y aseguré que los códigos se agrupen y combinen sin errores.

```

1. Valores unicos en Origin: ['GJT' 'HRL' 'DRO' 'IAH' 'DEN' 'TYS' 'MOB' 'LNK' 'BHM' 'IAD'
'ECP' 'AEX' 'LFT' 'BTR' 'ABQ' 'BUF' 'ALB' 'HSV' 'TUL' 'CPR']
3. Valores unicos en Dest: ['DEN' 'IAH' 'GPT' 'TUL' 'LCH' 'AEX' 'MOB' 'CPR' 'OKC' 'GJT'
'DRO' 'SAF' 'SHV' 'MFE' 'DIK' 'HRL' 'BTR' 'HSV' 'ICT' 'SGF']
5. Valores unicos en IATA_Code_Operating_Airline: ['C' 'G' 'ZW' 'YV' 'WN' 'YX' 'E' 'AA'
'PT' 'OO' 'AS' 'B' 'DL' 'F' 'HA' 'MQ' 'NK' 'OH' 'QX' 'UA']
7. Valores unicos en IATA_Code_Marketing_Airline: ['UA' 'WN' 'AA' 'DL' 'AS' 'B' 'F' 'G'
'HA' 'NK']

```

Dataset Aeropuertos

Para unir el dataset de aeropuertos con el de vuelos y poder trazar rutas y analizar retrasos por región, primero depuré la base de aeropuertos quedándome solo con los campos esenciales: el código IATA como llave de unión y las coordenadas de latitud y longitud para el análisis espacial. Con esa base lista, realicé la unión con el dataset principal de vuelos. Lo que hice fue combinar los registros de vuelos con las coordenadas de su aeropuerto de origen y destino, de manera que cada fila quedara enriquecida con origin_lat, origin_lon, dest_lat y dest_lon. Esta unión me permitió transformar un dataset puramente tabular en uno con dimensión geográfica, listo para análisis espaciales y visualizaciones en mapas.

1. **Faltan** coords origen: 23787 / 3944916
2. **Faltan** coords destino: 24126 / 3944916
3. **Origin** sin match (ejemplos): ['BQN', 'GUM', 'PPG', 'PSE', 'SJU', 'SPN', 'STT', 'STX']
4. **Dest** sin match (ejemplos): ['BQN', 'GUM', 'PPG', 'PSE', 'SJU', 'SPN', 'STT', 'STX']

Al revisar los resultados encontré que aproximadamente un 1.18 % de las filas no tenían coordenadas porque sus códigos IATA no aparecían en la tabla de aeropuertos. Analicé esos casos y comprobé que correspondían a territorios o aeropuertos especiales como Puerto Rico, Guam o las Islas Vírgenes, que no estaban cubiertos en la fuente secundaria. También verifiqué que esas filas no concentraban cancelaciones ni desvíos, lo que me fue decisivo para decidir eliminarlas debido al bajo número que maneja el dataset. Dropear ese 1.18 % me permitió quedarme con un dataset más limpio y consistente para los análisis espaciales, sin introducir sesgos en las métricas operativas. Esta limpieza me permitió ampliar la cantidad de datos originales sin perder la seguridad en que sean útiles para el futuro y no creen algún problema de desbalanceo de datos.

1. **Filas** sin coords: 46,587 / 3,944,916 (1.181%)
2. De esas: **Cancelled** 0.0%, **Diverted** 0.0%

Dataset FAA: Modelo Aviones

Al inicio de la integración de datos de aeronaves dudé entre enriquecer la información a partir de la aerolínea operadora o directamente por la matrícula del avión. La primera opción parecía más sencilla, pero pronto comprobé que en Estados Unidos la FAA (Federal Aviation Administration), una entidad pública, ofrece registros oficiales vinculados al tail number, con detalles como modelo y año de fabricación. Esto me permitió trabajar con una llave mucho más precisa y confiable. Para que la unión fuera consistente, normalicé las matrículas de los vuelos eliminando espacios y caracteres extraños, convirtiéndolas a mayúsculas y aplicando reglas específicas del registro estadounidense.

Con las matrículas ya alineadas, uní el dataset de vuelos con la base FAA y cada registro quedó enriquecido con el modelo y el año de fabricación de la aeronave. A partir de la fecha del vuelo calculé la edad del avión en años, una variable clave para analizar si la antigüedad influye en la puntualidad o en la probabilidad de cancelación. La salida del proceso, que se incluirá como imagen en el informe, muestra que de un total de 3,898,329 filas se encontraron coincidencias en 3,597,382 casos, lo que representa una cobertura del 92.28 %. A continuación, la salida por terminal.

1. Total filas: 3898329
2. Coincidencias con FAA (modelo encontrado): 3597382
3. Sin match (modelo NaN): 300947
4. Porcentaje de cobertura: 92.28%
5. Model desde FAA: 3597382 (92.28%)
6. Model inferidos: 300947 (7.72%)
7. Cobertura final (FAA + inferidos): 100.00%

Para el 7.72 % restante sin coincidencia en la FAA, implementé un mecanismo de inferencia basado en la aerolínea operadora, identifiqué el modelo más frecuente por aerolínea y lo imputé en los casos faltantes, recurriendo al modelo global más común cuando no había información específica. Este procedimiento permitió completar la cobertura al 100 %, siempre registrando el origen de cada dato para mantener trazabilidad. En el informe más adelante se mostrarán modelos obtenidos directamente de la FAA, modelos inferidos y el porcentaje de cobertura alcanzado.

$$aircraft_age = year(FlightDate) - YEAR_MFR$$

Para poner más detalle en el proceso, calculé la edad de cada avión restando el año de fabricación al año de la fecha del vuelo. Este indicador es fundamental porque permite analizar si la antigüedad de la flota influye en los retrasos, cancelaciones o desempeño operativo. A continuación, como se ve la unión dentro del dataset completo.

MODEL	AIRCRAFT_AGE
EMB-145XR	19.0
EMB-145XR	18.0
EMB-145XR	19.0
EMB-145XR	17.0
EMB-145XR	19.0

Una vez realizada la unión de los tres datasets, vuelos, aeropuertos y aeronaves, exporté el resultado a un nuevo archivo llamado Dataset_OData_Final_.csv para poder comenzar la fase de análisis con una base consolidada y reproducible. El proceso de limpieza y normalización permitió mantener prácticamente la misma cantidad de registros originales, pero con una estructura mucho más clara y enriquecida. El dataset final quedó compuesto por 62 columnas, reflejo de la integración de todas las dimensiones relevantes, y gracias a la depuración previa se evitó la pérdida significativa de datos, asegurando así una cobertura completa y lista para los análisis posteriores.


Proceso EDA

Debido a la gran cantidad de columnas y dimensiones que componen este dataset, abordar el Análisis Exploratorio de Datos requiere dividir el trabajo en distintas ramas según la naturaleza de cada variable. Comenzaré con una visión general del conjunto completo para entender su estructura, distribución y posibles inconsistencias globales, y a partir de ahí iré profundizando en bloques temáticos. Esta organización permitirá interpretar el comportamiento del dataset de forma ordenada, identificando patrones relevantes dentro de cada categoría ayudando a un análisis más específico según el interés en el campo.


Cabe destacar que la métrica de “superior a 15 minutos” lo usare como un estándar para el resto del análisis, ya que se suele tomar por analistas y profesionales en el campo como el punto crítico de decisión de si un vuelo tiene retraso o no.

Rama 0: Análisis General

Grafica 0: Composición global de vuelos en el Dataset Original




Para comenzar el EDA, realice una primera inspección general del dataset a través de dos visualizaciones complementarias. La Gráfica 0 , que representa la composición global de vuelos en el dataset original antes de la limpieza. En ella se observa que el 78.2 % de los vuelos fueron puntuales, con un retraso total menor o igual a 15 minutos, el 19.8 % fueron retrasados, el 1.8 % fueron cancelados y el 0.2 % fueron desviados. Esta distribución inicial refleja la diversidad de estados operativos presentes en los datos crudos.



Sin embargo, como se explicó en el proceso de limpieza, los vuelos cancelados y desviados presentaban valores nulos en las variables relacionadas con el retraso, lo que impedía calcular métricas como el tiempo total de demora. Por este motivo, y para garantizar consistencia en los análisis posteriores, decidí eliminar esas filas. La Gráfica 1 muestra la composición resultante tras esa depuración, donde el 77.48 % de los vuelos se consideran puntuales y el 22.52 % presentan retrasos superiores a 15 minutos.

Esta proporción entre clases es especialmente relevante de cara a futuros modelos predictivos. El hecho de que más de tres cuartas partes de los vuelos sean puntuales implica un claro desbalance de clases, algo que se tendrá que penalizar en el futuro o usar técnicas de balanceo,




Tras analizar la composición global de los vuelos, profundicé en el comportamiento específico de las variables continuas ArrDelayMinutes (retraso de llegada) y DepDelayMinutes (retraso de salida). En las Gráficas 2.1 y 2.2, representé la distribución completa de estos tiempos para todo el dataset. Lo primero que observé fue una asimetría positiva extrema, ya que la mayoría de los vuelos se concentran cerca del valor cero, pero con una cola larguísima que se extiende más allá de los 3,000 minutos. Un retraso de esa magnitud, lo mas probable, sea o por eventos climatológicos extremos o eventos fuera de lo común que hacen que las operaciones aéreas no se puedan completar.

Investigando fuera del análisis estos valores se deben al evento como “Southwest Airlines Scheduling Crisis” donde Estados Unidos vivió un colapso aereo histórico detonado por la tormenta invernal Elliot. El nombre fue debido a que la mas afectada fue la tercera empresa mas grande por volumen de pasajeros domésticos y mas del 60% de sus vuelos se cancelaron en menos de 2 dias. Esto fue debido a que su software de asignación de tripulaciones era obsoleto y no pudo procesar los cambios masivos, sumado a su modelo de rutas “punto a punto” que disperso a su personal por todo el país sin posibilidad de reubicarlos. Este evento dejo una multa récord de \$140 millones impuesta por el Departamento de Transporte


VARIABLE	25TH	50TH	75TH	90TH	99TH
ARR DELAYMINUTES	0	0	6	32	183
DEP DELAYMINUTES	0	0	5	33	186

Esta dispersión queda evidenciada al analizar los percentiles, donde el 50 % de los vuelos no tiene ningún retraso, 0 minutos, y que incluso el percentil 75 se sitúa en apenas 6 minutos para llegadas y 5 para salidas. Esto confirma que los valores extremadamente

altos son casos atípicos (*outliers*) que, aunque poco frecuentes, desplazan la escala de las gráficas y dificultan la visualización del grueso de la operación.



Para corregir este efecto y observar con mayor detalle el comportamiento de la masa principal de datos, decidí generar las Gráficas 2.3 y 2.4, truncando el eje horizontal entre 0 y 184 minutos (valor cercano al percentil 99). Al hacer zoom en este rango, identifiqué con mayor claridad la caída exponencial en la frecuencia a medida que aumentan los minutos de retraso. He incluido una línea punteada roja que marca el umbral de 15 minutos; esta frontera visual permite apreciar cómo la mayor parte de la densidad de probabilidad se acumula a la izquierda del umbral, lo que ratifica el desbalance de clases mencionado anteriormente.




Finalmente, en la **Gráfica 3.1**, comparé el volumen de vuelos que superan el umbral de 15 minutos. He observado que la incidencia es prácticamente idéntica en ambos casos, alcanzando un **16.59 %** de los vuelos totales tanto para salidas como para llegadas. Esto me indica que el fenómeno del retraso afecta de manera muy equilibrada a ambas fases del vuelo.

Posteriormente, en la **Gráfica 3.2**, analicé la magnitud promedio de estas demoras. He verificado que los valores medios son sumamente cercanos: **12.65 minutos** para salidas frente a **12.49 minutos** para llegadas. Esta mínima diferencia me sugiere una correlación muy fuerte entre ambos eventos; es decir, la demora acumulada en la salida tiende a propagarse casi íntegramente hasta el aterrizaje, sin que se aprecie una recuperación significativa de tiempo durante el trayecto.


Rama 1: Comparativa de mercado por Modelo y/o Aerolínea

Para iniciar, en la industria aérea es común que la aerolínea que comercializa el vuelo (*Airline*) sea distinta a la que opera el avión (*Operating_Airline*), lo cual podría introducir ambigüedad al asignar la responsabilidad de los retrasos. Por ello, ejecuté una validación comparando ambas columnas para todos los registros. Al confirmar que en la totalidad de los registros la aerolínea comercial y la operadora coinciden, pude simplificar el análisis utilizando la variable *Operating_Airline* como el identificador único, descartando así problemas de duplicidad o inconsistencia en la atribución de los datos.



Una vez validada, generé la **Gráfica 4.1** para examinar el **retraso medio (en minutos)** por aerolínea. Lo que observé revela una disparidad significativa, mientras que **Commutair Aka Champlain Enterprises** lidera negativamente el ranking con un retraso medio superior a los 23 minutos, seguida por **Allegiant Air** y **JetBlue**, en el extremo opuesto encontramos a compañías como **Empire Airlines** y **Hawaiian Airlines**, cuyos retrasos medios apenas rondan los 5 minutos. Esta brecha de casi 20 minutos de media entre la mejor y la peor aerolínea sugiere que la variable "aerolínea" posee un alto poder predictivo, ya que el comportamiento de los retrasos no es uniforme en el mercado.

Para complementar esta visión, analicé la **Gráfica 4.2**, que muestra el **porcentaje de vuelos retrasados**, pero dentro del umbral de 15 minutos. Aquí noté un matiz, aunque Commutair tenía el peor promedio de tiempo, es **Allegiant Air** la que presenta la mayor frecuencia de incidencias, con casi un 30 % de sus vuelos sufriendo retrasos. Esto indica que, si bien Commutair tiene retrasos más largos cuando ocurren, Allegiant falla con mayor regularidad. De igual forma, aerolíneas como **Southwest** y **Frontier** se mantienen en la parte alta de la tabla de frecuencia. En contraste, Endeavor Air y Hawaiian Airlines confirman su robustez operativa, mostrando las tasas de impuntualidad más bajas del dataset.




Para dar un contexto realista a las métricas de retraso analizadas anteriormente, generé la **Gráfica 4.3**, donde visualizo la frecuencia de vuelos operados por las 20 principales aerolíneas del dataset.

El caso más ilustrativo de esta relación es el de **Hawaiian Airlines**. Si bien en las gráficas anteriores destacué su liderazgo indiscutible en, la Gráfica 4.3 revela que es la compañía con menor volumen de operaciones dentro del Top 20. Esto me sugiere que su excelente rendimiento no solo depende de una buena gestión, sino que probablemente esté favorecido por una menor complejidad logística, rutas menos congestionadas y una escala operativa mucho más reducida.


Otra conclusión fue al observar el comportamiento de **Southwest Airlines**, que domina abrumadoramente el dataset con más de un millón de vuelos registrados. Al analizar su desempeño con esto en cuenta, su posición intermedia en las tablas de retrasos cobra mayor importancia. Esto es ya que mantener niveles de servicio aceptables gestionando un volumen de tráfico tan masivo implica desafíos de coordinación y mantenimiento mucho mayores que el resto de las aerolíneas.

Para profundizar en las causas operativas de los retrasos, decidí cambiar el foco de las aerolíneas a los modelos en sí. Mi hipótesis inicial era que ciertas aeronaves, debido a sus características técnicas o al tipo de rutas para las que se utilizan, podrían ser más propensas a generar demoras.

En la **Gráfica 5.1**, identifiqué los 20 modelos más utilizados en el dataset. Lo que más me llamó la atención fue el predominio absoluto del modelo “**ERJ 170-200 LR**”, un jet regional que acumula más de 800,000 vuelos, superando por mucho al segundo competidor, el Boeing 737-7H4. La fuerte presencia de modelos de la familia ERJ y CRJ en este "Top 20" me indica que una gran parte de la operativa registrada corresponde a vuelos de corta y media distancia, que suelen tener frecuencias de rotación muy altas y tiempos de escala menores. Aun así esto último se evaluara más adelante.




Al cruzar esta información con el desempeño en puntualidad en la Gráfica 5.2, encontré patrones reveladores. Observé que de la familia Airbus A320 (específicamente las variantes -214, -232 y -251N) ocupa los primeros puestos en retraso medio, alrededor de los 15-19 minutos. En contraste, el Boeing 717-200 se destaca como el modelo más eficiente, con un retraso medio de apenas 5 minutos. Es interesante notar que el modelo más frecuente, el ERJ 170-200 LR, mantiene un rendimiento bastante aceptable (10-11 min), situándose en la parte baja de la tabla a pesar de su gran volumen de operaciones.



Para profundizar en el impacto del equipamiento, decidí ampliar el espectro de mi análisis más allá de la frecuencia de uso. Generé la **Gráfica 6.1**, que muestra los 20 modelos con mayor retraso medio sin aplicar filtros de volumen. Al observar estos resultados, noté que modelos como el **A321-271NX** y el **777-323ER** encabezan la lista con demoras promedio que superan los 24 y 27 minutos respectivamente. Sin embargo, identifiqué un riesgo estadístico importante: muchos de estos modelos podrían tener promedios inflados debido a que operan muy pocos vuelos, donde un solo incidente grave dispara la media.

Métrica	Valor
Count	100
50%	13,426
75%	66,914
90%	189,584
95%	236,870

Para obtener conclusiones más robustas y representativas de la operativa real, decidí aplicar un filtro basado en la distribución de frecuencia de vuelos del dataset. Observé que el percentil 75% es de aproximadamente **66,914 vuelos** y lo usé como umbral de confianza para generar la **Gráfica 6.2**.




Al filtrar por este volumen mínimo, el panorama cambió sustancialmente y obtuve una visión mucho más fiable. He comprobado que el **EMB-145XR** se posiciona como el modelo con peor desempeño operativo bajo condiciones de alta frecuencia, con un retraso medio superior a los 23 minutos. También, de la familia Airbus, específicamente el **A320-214** y el **A320-232**, reaparecen con retrasos consistentes que oscilan entre los 17 y 19 minutos. Esto me confirma que su baja puntualidad no es una anomalía estadística producto de pocos vuelos, sino un patrón en su operación habitual.

En el otro extremo de la gráfica, modelos como el **CL-600-2D24** y el **ERJ 170-200 LR**, este último siendo el más frecuente de todo el conjunto de datos, demuestran una fiabilidad notable. Ambos mantienen medias de retraso muy bajas, cercanas a los 10 minutos, a pesar de soportar una altísima carga de trabajo.

Para refinar aún más, decidí agrupar los cientos de modelos individuales por familias de aeronaves. Al observar la **Gráfica 7.1**, el resultado es concluyente, la familia de los **A350** y los **Boeing 777** lideran los tiempos de demora con promedios que superan los 20 minutos. Esto me sugiere que los aviones de fuselaje ancho, destinados generalmente a rutas internacionales o de largo radio, enfrentan procesos de carga, embarque y gestión mucho más complejos que impactan directamente en su puntualidad.

Lo mismo sucede con los **Embraer**, donde el **EMB-145XR** duplica el retraso de modelos como el **ERJ 170-100 STD**. Incluso en los **B737**, variantes como el **737-73V** presentan una impuntualidad mucho mayor que la media de su línea.

Estos hallazgos confirman que la familia es solo un marco general y que el modelo específico es el predictor real. También, esta realidad refleja cómo la continua revisión de un modelo o familia, como sucede con los **Boeing 737**, impacta en la eficiencia operativa. La gran variedad de variantes y la actualización hacia aeronaves más nuevas sugiere que este proceso de cambio constante afecta directamente al retraso. Esto puede ser como sucede con el **737-8** que es la versión más reciente de su línea en este análisis, y aparece dentro de los modelos con más retraso.




Para cerrar la Rama 1, generé un **Heatmap (Gráfica 8.1)** que cruza aerolíneas con familias de aeronaves, sintetizando todos los hallazgos previos. Esta visualización confirma que el retraso resulta de la interacción entre la gestión corporativa y el equipo físico. He observado que **United Airlines Inc.** presenta ineficiencias transversales, con retrasos superiores al 20 % en casi todas sus familias lo que sugiere problemas logísticos estructurales independientes de la modernidad del avión.

En contraste, el mapa revela éxitos focalizados en **Delta Air Lines Inc.**, una de las empresas con más vuelos. Logra una gestión impecable en la familia **B787** (9.5 % de retrasos), mientras que la familia **A350** bajo su operación alcanza un crítico 31.5 %. Esto refuerza que los aviones de fuselaje ancho son más complejos de gestionar. Por otro lado, la especialización regional sigue siendo la estrategia más robusta, como demuestra **Endeavor Air Inc.** con la familia **CRJ** (8.3 % de retraso).


En conclusión, futuros modelos predictivos deben capturar esta intersección, ya que la aerolínea puede mitigar o empeorar las deficiencias naturales de un modelo, siendo este cruce el factor con mayor valor informativo.

Rama 2: Edad de la Aeronave y su efecto

Para continuar con el informe, inicio la Rama 2, donde analizo cómo influye la edad de los aviones en la puntualidad de las operaciones. Mi objetivo en esta sección es determinar si existe un empeoramiento operativo vinculado a los años de servicio de la aeronave o si, por el contrario, los programas de mantenimiento logran mitigar el paso del tiempo.




Al observar la Gráfica 9.1, la distribución de la edad de la flota en el dataset es claramente bimodal. El primer pico de gran volumen se concentra en aeronaves jóvenes, de entre 1 y 5 años, lo que refleja una renovación importante de la flota por parte de varias compañías. Posteriormente, el volumen de vuelos desciende notablemente en el rango de los 10 años, para volver a subir con fuerza en un segundo pico situado alrededor de los 15 y 16 años de antigüedad. Finalmente, la actividad decae de forma drástica a partir de los 23 años, quedando una representación mínima de aviones que alcanzan o superan los 30 años de servicio.



En cuanto al impacto directo en la puntualidad, las Gráficas 9.2 y 9.3 revelan un comportamiento complejo. No he encontrado una tendencia lineal simple que indique que a mayor edad existan más retrasos; en cambio, los datos muestran una alta volatilidad. Es destacable que los aviones más nuevos (0 a 3 años) mantienen niveles de retraso medio y frecuencia de incidencias bastante bajos, pero se observa un pico de ineficiencia crítico precisamente en el grupo de los 15 años, coincidiendo con el segundo máximo de población de la flota.

Esta falta de una pendiente ascendente clara me sugiere que la edad cronológica por sí sola no es el factor determinante del retraso. He verificado que aeronaves con 25 o 28 años de servicio pueden presentar incluso menos demoras que modelos con 15 años, lo que refuerza la idea de que la calidad del mantenimiento preventivo y el tipo de rutas asignadas a los aviones más veteranos compensan el envejecimiento del material. Por tanto, para el modelado predictivo, la edad deberá ser tratada con cuidado, entendiendo que su efecto está condicionado por la intensidad de uso y los ciclos de revisión técnica de cada unidad.

Sin embargo, la volatilidad se hace aún más evidente en el tramo final de la vida útil de las aeronaves. Al observar el intervalo entre los 25 y 30 años, he detectado un repunte severo y abrupto en ambas métricas, donde el retraso medio llega a alcanzar su punto máximo cerca de los 16 minutos y la frecuencia de demoras supera el 19%. Este comportamiento sugiere que, tras superar la etapa de madurez, los aviones más veteranos sufren un desgaste que ni siquiera el mantenimiento preventivo logra compensar totalmente.




Para cerrar esta rama, el Heatmap (Gráfica 9.4) confirma visualmente que no existe una relación lineal o directa entre la edad de la aeronave y el retraso. Al cruzar la antigüedad con las aerolíneas, se observa una dispersión de colores donde los puntos críticos de demora no se concentran en un rango de edad específico, sino que aparecen de forma aislada en diferentes etapas. Por ejemplo, Allegiant Air presenta su mayor tasa de retrasos en aviones de apenas 8 años, mientras que JetBlue Airways muestra una ineficiencia sostenida en casi toda su escala temporal, independientemente de si el avión tiene 2 o 20 años. United Air Lines Inc. mantienen una estabilidad de retrasos moderada pero constante a lo largo de 30 años de flota. Esto demuestra que un programa de mantenimiento sólido puede igualar el rendimiento de un avión veterano al de uno recién salido de fábrica, haciendo que la antigüedad sea una variable con mucho ruido estadístico.

En conclusión, la edad solo aporta valor predictivo real al combinarse con la identidad de la aerolínea, ya que el impacto de los años no es estricto, sino el resultado de cómo cada empresa decide gestionar el envejecimiento y la rotación de su flota.

Rama 3: Impacto de congestión y Franjas horarias

Para esta nueva rama analizo cómo la saturación estacional y horaria condiciona la puntualidad, identificando patrones cíclicos que los modelos predictivos deben capturar.

Para este análisis, sistematicé los retrasos en cuatro categorías estratégicas. Los rangos de 0 a 5 minutos (Small) y de 5 a 15 minutos (Medium) se definieron así porque, en la operativa real, retrasos menores a 15 minutos suelen ser absorbibles por el sistema y no se consideran faltas graves de puntualidad. Después de 15 a 35 lo considere un gran retraso, (Large). El umbral de más de 35 minutos para categorizar un retraso como Massive responde a un criterio estadístico basado en la distribución de los datos, donde los eventos que superan este tiempo representan incidencias severas que rompen la cadena logística de las aerolíneas.




Al observar las Gráficas 10.1a y 10.1b, identifiqué una estacionalidad crítica. Existe una concentración máxima de "Massive Delays" en junio, julio y agosto, con picos del 34.1% y 35.0%. Esta saturación veraniega se debe al drástico aumento de pasajeros y a la temporada de tormentas eléctricas, factores que obligan a imponer restricciones de flujo por seguridad y por alta demanda. Los meses de primavera, con menor tráfico y clima estable, presentan los niveles más bajos de retrasos severos, rondando el 21%.

Finalmente, verifiqué que en diciembre vuelve a subir la categoría de retrasos masivos (30.4% en salidas y 31.5% en llegadas) debido a las festividades invernales y el clima adverso. Esta ciclicidad confirma que la congestión estacional es un predictor de gran peso, ya que el sistema opera al límite de su capacidad en estas fechas, elevando el riesgo de demoras que futuros algoritmos ML deben de aprender a anticipar.



También he analizado la distribución horaria y diaria de los retrasos mediante los Heatmaps 10.2a y 10.2b, los cuales revelan el factor de congestión más determinante de todo el estudio, el efecto del ciclo diario de operaciones. Una anomalía crítica en las franjas de la madrugada (01:00 a 04:00 AM), donde los porcentajes de retraso >15 min se disparan por encima del 50%, llegando a picos extremos de hasta el 98.2% en llegadas los jueves. Estos valores tan elevados en horas de bajo tráfico se explican por el efecto propagación, ya que estos vuelos suelen ser unidades retrasadas que debieron operar el día anterior. Al volar fuera de su franja original, el sistema los registra casi en su totalidad como vuelos con demora masiva, arrastrando las ineficiencias de toda la jornada previa.


En cuanto al ciclo operativo estándar (05:00 a 23:00), hay una tendencia de crecimiento acumulativo, mientras que a las 05:00 AM la probabilidad de retraso es mínima, inferior al 2%, el valor aumenta de forma progresiva hasta alcanzar el 30-37% al final del día. Esta saturación progresiva demuestra que el sistema carece de capacidad de recuperación inmediata. Al cruzar esto con los días de la semana, los **jueves, viernes y domingos** aparecen como los días de mayor riesgo debido al volumen de viajes de negocios y ocio. En conclusión, la hora de salida es un predictor incluso más potente que el mes o la aerolínea, confirmando que la congestión diaria es un factor crítico que el modelo debe aprender a anticipar.




Para profundizar en la relación entre la saturación y la puntualidad, he contrastado la tasa de retrasos con el volumen real de operaciones mediante las **Gráficas 11.1 y 11.2**. Esta comparativa revela una desconexión crítica: la gran cantidad de retrasos no se relaciona proporcionalmente con el volumen de vuelos. Mientras que el pico máximo de actividad se registra entre las 08:00 y las 10:00 AM con más de 400,000 vuelos, los niveles de retraso en esa franja son de los más bajos del día, apenas rozando el 10%.

Por el contrario, el escenario se invierte drásticamente durante la noche y madrugada. Es precisamente cuando hay menos vuelos en el aire cuando el porcentaje de retrasos se dispara a sus niveles máximos, superando el 50% en salidas y el 90% en llegadas. Este fenómeno confirma que el retraso nocturno no es fruto de la congestión del momento, sino de la herencia de problemas acumulados durante las horas pico de la mañana; el sistema no colapsa por el tráfico presente, sino por su incapacidad de absorber las demoras previas en una red aérea ya estresada. Aun así también puede ser por factores externos del clima como: Niebla más difícil de detectar, posibles problemas de iluminación de la pista y tráfico aéreo intenso.

Para concluir el análisis temporal, el Calendario Anual (Gráfica 11.3) sintetiza la evolución de la impuntualidad a lo largo de 2021, confirmando visualmente lo mencionado previamente.




También, he analizado la constancia de los retrasos mediante Lag Plots, y los coeficientes de Pearson revelan que la dependencia lineal es, en realidad, muy débil o inexistente en casi todos los aeropuertos. Incluso en el grupo de alta incidencia. Aeropuertos como BIH presentan una correlación negativa de -0.06 y LCK apenas alcanza un 0.02, lo que indica que el retraso de un vuelo no predice linealmente el del siguiente. Solo en casos muy específicos como Dallas Love Field (DAL) se observa una correlación moderada de 0.46, siendo la excepción donde sí existe una conclusión de la demora. Cabe destacar que son puntos menores a 300 minutos para que la gráfica se vea correctamente.




Esta falta de correlación se confirma de forma absoluta en los aeropuertos de baja incidencia como ITO o DBQ, donde los coeficientes son prácticamente nulos (0.05 y -0.02 respectivamente) y las líneas de tendencia se mantienen planas. Estos datos demuestran que el retraso es un fenómeno mayoritariamente carente de un patron lineal.

Análisis de Persistencia de Retrasos - Baja Incidencia




Rama 4: Impacto de TaxiOut, TaxiIn y eventos WheelsOff/WheelsOn

En esta fase examino cómo los tiempos de rodaje en pista y las fases críticas del vuelo influyen en la cadena de demoras. El objetivo es identificar si el cuello de botella operativo ocurre antes de despegar o tras el aterrizaje, y cómo la eficiencia en tierra varía según el aeropuerto y la hora del día.



Al observar los Heatmaps 13.1 y 13.2, he identificado un contraste drástico entre la eficiencia de los aeropuertos con más y menos retrasos. En los nodos de alta incidencia, el TaxiOut, tiempo desde que el avión deja la puerta hasta que despegue, muestra una saturación térmica constante, con valores que frecuentemente superan los 20 o 30 minutos.


En cambio, los aeropuertos con menos retrasos muestran una matriz de TaxiOut mucho más fría y dispersa, con tiempos que suelen mantenerse en niveles óptimos de eficiencia. Es notable que incluso en estos aeropuertos existen picos aislados de saturación muy severos en franjas horarias específicas, como se observa en EKO (Elko) alrededor de las 09:00 AM, donde el TaxiOut se dispara a niveles críticos representados en azul oscuro. Esto me indica que, aunque un aeropuerto sea generalmente puntual, eventos puntuales de saturación en pista pueden romper la fluidez del evento WheelsOff.



Finalmente, para validar el peso real de las operaciones en tierra sobre el retraso total, he analizado la correlación entre los tiempos de rodaje y las demoras mediante los **Diagramas de Dispersión 14.1 y 14.2**. Los resultados son contundentes: existe una **poca o nula relación lineal** entre estas variables, como demuestran los coeficientes de Pearson extremadamente bajos de **0.028** para TaxiOut y **0.078** para TaxiIn. Esto significa que, aunque un avión pase mucho tiempo en las calles de rodaje, ese factor por sí solo no explica la magnitud del retraso final en la salida o la llegada; la nube de puntos muestra que existen vuelos con rodajes cortos que sufren retrasos masivos y viceversa.


Esta falta de correlación refuerza la hipótesis de que el retraso es un fenómeno multifactorial donde el tiempo en pista es solo un componente menor frente a la congestión estacional o la acumulación horaria. Algo a tener en cuenta mas adelante a la hora de hacer modelos de predicción, donde hacer un análisis de los componentes principales es beneficioso cuando hay una alta dimensionalidad o cantidad de variables, como en nuestro caso con más de 50 columnas.

Para añadir, he desglosado la relación entre el tiempo de rodaje y el retraso medio en los seis aeropuertos con mayor tráfico (ATL, CLT, DEN, DFW, LAX, ORD). Los resultados en las Gráficas 14.3 y 14.4 contradicen la intuición operativa inicial y convencional, ya que muestran que un mayor tiempo de rodaje no se traduce necesariamente en mayores retrasos. En el caso del TaxiOut, la tendencia suele ser neutra o incluso descendente, lo que sugiere que el tiempo en pista es un factor ya previsto por la gestión aeroportuaria y no la causa raíz de la impuntualidad.




Esta desconexión en ambas figuras se debe a que el flujo en tierra depende de factores externos y logísticos que no siempre son lineales, como la saturación de las frecuencias de radio de la torre de control, fallos en la comunicación entre pilotos y tierra, o los tiempos de espera obligatorios entre que una aeronave libera la pista y la siguiente recibe autorización para entrar.

En el caso del TaxiIn, aunque aeropuertos como Atlanta (ATL) muestran una pendiente positiva, la enorme dispersión de los datos en otros aeropuertos como DFW confirma que el retraso final responde a un colapso de coordinación externa y no simplemente a la distancia recorrida en pista. En definitiva, estas gráficas no muestran la relación directa que se esperaba porque la eficiencia depende de una cadena de mando y eventos externos que los modelos lineales simples no pueden capturar. Como dijimos antes, se deberá tener en cuenta a futuro.




Para profundizar en la eficiencia operativa por compañía, la Gráfica 14.2 presenta una descomposición del tiempo total de vuelo, permitiendo distinguir qué aerolíneas enfrentan mayores desafíos en tierra. He observado una disparidad significativa en el peso del TaxiOut, que oscila entre un mínimo del 7.9% para Hawaiian Airlines Inc., una de las aerolíneas con menos retraso medio, y un máximo del 23.4% para Air Wisconsin Airlines. Esta diferencia sugiere que el rodaje antes del despegue no es un factor estándar de la industria, sino un problema logístico que ciertas aerolíneas deben priorizar en su gestión de costes y puntualidad, especialmente aquellas con modelos de negocio regionales que operan en aeropuertos congestionados, no como en el caso de Hawaiian.

En cuanto al TaxiIn, el impacto es notablemente menor y más uniforme, representando generalmente entre el 4% y el 9% del tiempo total de la operación. No obstante, casos como el de Empire Airlines Inc., donde el TaxiIn alcanza el 14.7%, indican ineficiencias críticas tras el aterrizaje que podrían estar ligadas a la asignación de puertas o a la coordinación con los servicios de tierra. En conclusión, estos datos reflejan que las aerolíneas deben monitorizar estos tiempos no solo como una métrica de puntualidad, sino como un factor de consumo de combustible y rotación de flota, ya que la acumulación de minutos en pista representa una ineficiencia para la empresa.



Para culminar esta rama del análisis, he contrastado la composición del tiempo de vuelo entre los 10 aeropuertos con mayor y menor retraso medio mediante las Gráficas 14.4 y 14.5. Los resultados confirman una incongruencia, los aeropuertos más impuntuales no presentan necesariamente una mayor proporción de tiempo en tierra. De hecho, nodos con retrasos críticos como BIH o GUC destinan porcentajes de TaxiOut (18.6% y 26.0%) muy similares a los de aeropuertos altamente puntuales como DBQ o GST, donde el rodaje previo al despegue alcanza el 22.4% y el 40.1% respectivamente. Esta similitud en los pesos relativos del tiempo en pista demuestra que una estructura operativa aparentemente "ineficiente" o lenta no es la causa directa del delay masivo.



En este sentido, el análisis del AirTime revela que el tiempo de vuelo actúa como una "constante rígida" que no permite absorber las ineficiencias previas. En los aeropuertos con más retraso, el tiempo en el aire representa cerca del 70% del total porque el 30% restante se pierde en fricciones terrestres, lo que deja al vuelo sin margen de maniobra para recuperar minutos una vez despega.

Es importante destacar que este menor porcentaje de AirTime en aeropuertos congestionados podría sugerir un intento por parte de las aerolíneas de aumentar la velocidad de crucero para intentar recortar el retraso acumulado; sin embargo, al observar que la proporción sigue siendo baja, queda claro que este esfuerzo es insuficiente frente al tiempo ya perdido en tierra. Por el contrario, en aeropuertos extremadamente puntuales como LIH, el AirTime devora casi todo el gráfico con un 89.6%, lo que es señal de una operación limpia y correctamente lineal donde el avión dedica casi todo su ciclo a volar en lugar de estar parado acumulando ineficiencias. Esta rigidez confirma que el retraso no se soluciona fácilmente en el aire mediante incrementos de velocidad, sino que se genera o se evita en tierra. Por lo tanto, el tiempo de vuelo es el factor dominante en duración, pero el más irrelevante para explicar la impuntualidad.

Como la conclusión general de esta rama, el porcentaje de tiempo dedicado a TaxiIn, TaxiOut y AirTime responde más al diseño de la infraestructura y a la naturaleza del trayecto que a la generación de demoras en sí misma.

Conclusiones

Como conclusión general, este reporte constituye un análisis completo de la operatividad aérea, revelando que el retraso de los vuelos es un fenómeno multivariante donde la infraestructura, el factor humano y la gestión logística pesan más que la duración física del vuelo. A nivel general, los datos demuestran que no existe una relación lineal directa entre la magnitud de la operación y el nivel de impuntualidad. Se ha observado que la puntualidad depende más de la robustez de los procesos, lo que justifica un análisis profundo de las variables técnicas y temporales para comprender las desviaciones en el servicio.

En la Rama 1, dedicada a la comparativa de mercado, los datos reflejan que la puntualidad no es uniforme entre compañías. Mientras que aerolíneas comerciales como Southwest Airlines Co. o Delta Air Lines Inc. logran estabilizar sus operaciones mediante prioridades en sus hubs, el análisis de modelos de avión revela disparidades técnicas. Se identificó que modelos como el Boeing 737-800 o el Airbus A320 presentan perfiles de demora muy específicos comparados con aeronaves regionales, lo que sugiere que la combinación de la aerolínea operadora y el tipo de equipo utilizado condiciona directamente la estabilidad operativa del trayecto.


La Rama 2 permitió desmitificar la idea de que la edad de la aeronave es el detonante principal de los retrasos. El análisis demostró que el mantenimiento preventivo y la gestión de la rotación de flota neutralizan el efecto de la antigüedad física. Los datos indican que aeronaves con más de 20 años de servicio, comunes en flotas de aerolíneas como Delta o United, no presentan necesariamente mayores retrasos técnicos que aviones recién incorporados de Spirit o JetBlue. Se concluye que un activo correctamente mantenido es tan puntual como uno nuevo, desplazando el foco de la culpa hacia la logística terrestre y no hacia la fecha de fabricación de la aeronave.

En la Rama 3, el estudio del impacto de la congestión y las franjas horarias confirmó que el tiempo es el recurso más importante. Los datos evidenciaron que el retraso crece de manera acumulativa durante las horas pico, saturando la capacidad operativa de grandes aeropuertos como ATL (Atlanta) o DFW (Dallas/Fort Worth). Este comportamiento confirma que el sistema tiene una capacidad de recuperación limitada, y una vez que se entra en las franjas de mayor actividad, cualquier pequeña incidencia en la rotación de aviones se amplifica, transformando la operación en un foco de demora masiva.

Finalmente, en la Rama 4, el análisis de los tiempos de TaxiOut, TaxiIn y eventos de pista confirmó que el retraso es fundamentalmente un problema de gestión en tierra. El estudio mostró que en aeropuertos congestionados como CLT (Charlotte), el tiempo de rodaje es significativamente más alto, haciendo que el AirTime represente un porcentaje menor (cerca del 70%) debido a las fricciones en pista. Aunque las aerolíneas intenten aumentar la velocidad de crucero, este esfuerzo es insuficiente para recuperar el tiempo perdido en tierra. Por el contrario, la fluidez en aeropuertos como LIH (Lihue), donde el tiempo de vuelo efectivo alcanza el 89.6%, subraya que la clave de la puntualidad reside en minimizar las ineficiencias logísticas entre las fases de WheelsOff y WheelsOn.

Ideas y Cambios a Futuro

Para cerrar el reporte, la sección de Ideas y Cambios a Futuro se proyecta como el puente natural entre el análisis exploratorio realizado y la implementación de soluciones de modelos predictivos. La meta principal es transicionar del entendimiento descriptivo a la capacidad predictiva mediante el uso de modelos de regresión y clasificación. Actualmente, con la sólida base de información obtenida en las cuatro ramas del EDA, ya es posible desarrollar modelos de regresión para estimar el tiempo exacto de retraso. Sin embargo, para dotar al sistema de una capacidad de clasificación robusta que categorice la severidad de las demoras, es imperativo abordar la rama pendiente: el mapeo geoespacial completo de las rutas aéreas.



Esta fase futura requiere integrar las coordenadas de latitud y longitud de cada aeropuerto para trazar las trayectorias de vuelo. Aunque el trazado mediante líneas rectas representa una aproximación simplificada de las rutas reales, es la metodología más viable y precisa disponible para este nivel de análisis. Este mapeo cartográfico no solo tendría un valor visual, sino que permitiría realizar un filtrado avanzado por estado, nodo aeroportuario y modelo de aeronave. Como se puede ver en la imagen de arriba donde filtro para el mes de Abril y con distancia mayor a 2800 millas, dando resultado vuelos mayoritariamente a las islas de Hawaii. Al cruzar la geografía con la operativa, se podrá determinar si ciertas regiones geográficas presentan cuellos de botella sistémicos que no son detectables mediante tablas estadísticas convencionales.

Finalmente, esta expansión geoespacial abrirá la puerta al uso de técnicas de aprendizaje no supervisado para segmentar el mercado aéreo de forma inteligente. En esta sección se iniciaría la implementación de modelos de clustering, como K-means o DBSCAN, orientados a agrupar aeropuertos y rutas según el volumen de tráfico, la densidad de puntos de salida y las distancias recorridas. Por ejemplo, DBSCAN permitiría identificar clústeres de alta congestión basados en la proximidad geográfica y temporal, separando el "ruido" de los vuelos aislados de las verdaderas acumulaciones de tráfico. Estos cambios a futuro no solo enriquecerán el análisis visual, sino que proporcionarán las etiquetas y estructuras necesarias para que los modelos de Machine Learning alcancen una precisión muy superior en sus predicciones.